UNIVERSIDAD PANAMERICANA

CIUDAD UP · FACULTAD DE CIENCIAS EMPRESARIALES

Series de Tiempo para Finanzas

Pregunta & Respuesta — Nivel Quant

ARIMA(p, d, q) · SARIMA · SARIMAX · Pronóstico

Dr. César Galindo Verano 2026

0. Contents

1 Procesos estacionarios y fundamentos **2**
1.1 Ejercicio 1.1 — Estacionariedad, ACF y PACF . . . 2
1.2 Ejercicio 1.2 — Procesos AR, MA y ARMA . . . 5
1.3 Ejercicio 1.3 — Raíces unitarias y prueba de Dickey-Fuller . . . 8

2 Modelos ARIMA(p, d, q) **11**
2.1 Ejercicio 2.1 — Identificación, estimación y diagnóstico . . . 11
2.2 Ejercicio 2.2 — ARIMA(1,1,1) para log-precios . . . 13
2.3 Ejercicio 2.3 — Pronóstico con ARIMA(2,1,0) . . . 15
2.4 Ejercicio 2.4 — Cointegración y spreads estadísticos . . . 16

3 Modelos SARIMA y estacionalidad **18**
3.1 Ejercicio 3.1 — Estructura y notación SARIMA . . . 18
3.2 Ejercicio 3.2 — Modelo de Airline . . . 19
3.3 Ejercicio 3.3 — SARIMA para CETES . . . 20
3.4 Ejercicio 3.4 — Descomposición STL . . . 20

4 Modelos SARIMAX con variables exógenas **22**
4.1 Ejercicio 4.1 — ARIMAX . . . 22
4.2 Ejercicio 4.2 — SARIMAX demanda eléctrica . . . 22
4.3 Ejercicio 4.3 — SARIMAX ventas con calendario . . . 23

5 Simulación, Yule-Walker e interpretación gráfica **25**
5.1 Ejercicio 5.1 — Yule-Walker . . . 25
5.2 Ejercicio 5.2 — Simulación AR(2) . . . 26
5.3 Ejercicio 5.3 — Tabla de rendimientos IPC . . . 27
5.4 Ejercicio 5.4 — Simulación SARIMA estacional . . . 27
5.5 Ejercicio 5.5 — Comparación de modelos . . . 28
5.6 Ejercicio 5.6 — Monte Carlo . . . 29

1. Procesos estacionarios y fundamentos

Ejercicio 1.1 — Estacionariedad, ACF y PACF

Defina estacionariedad débil y estricta. Dé un ejemplo de un proceso débilmente estacionario que no sea estrictamente estacionario.

Respuesta 1.1(a)

Contexto y motivación. La estacionariedad es la propiedad fundamental que hace posible la inferencia estadística en series de tiempo: si los parámetros del proceso cambian con el tiempo, no podemos aprender nada estable de los datos. En finanzas cuantitativas, trabajar con series no estacionarias sin las transformaciones adecuadas conduce a regresiones espurias, intervalos de confianza incorrectos y estrategias de trading con rendimientos ilusorios.

Estacionariedad débil (de covarianza). El proceso $\{Y_t\}_{t\in\mathbb{Z}}$ es *débilmente estacionario* (o estacionario de segundo orden) si:

(i) $\mathrm{E}[Y_t] = \mu \quad \forall\, t$ (media constante, independiente del tiempo),
(ii) $\mathrm{E}[Y_t^2] < \infty \quad \forall\, t$ (varianza finita),
(iii) $\mathrm{Cov}(Y_t, Y_{t-k}) = \gamma(k) \quad \forall\, t, k$ (la autocovarianza depende *sólo* del rezago k, no de t).

La función $\gamma : \mathbb{Z} \to \mathbb{R}$ se llama *función de autocovarianza* (ACVF). Nótese que $\gamma(0) = \mathrm{Var}(Y_t)$ es la varianza del proceso.

Estacionariedad estricta. El proceso es *estrictamente estacionario* si para todo $m \geq 1$, todo $(t_1, \ldots, t_m) \in \mathbb{Z}^m$ y todo $h \in \mathbb{Z}$:

$$(Y_{t_1}, \ldots, Y_{t_m}) \stackrel{d}{=} (Y_{t_1+h}, \ldots, Y_{t_m+h}).$$

En palabras: la distribución conjunta de cualquier subconjunto finito de la serie es invariante a traslaciones en el tiempo.

Relación entre ambas. La estricta implica la débil (siempre que existan los segundos momentos), pero no viceversa. La excepción es cuando el proceso es gaussiano: un proceso gaussiano es estrictamente estacionario si y sólo si es débilmente estacionario, porque la distribución gaussiana queda completamente determinada por su media y covarianza.

Ejemplo canónico. Sea

$$Y_t = A\cos(\omega t) + B\sin(\omega t),$$

donde A y B son variables aleatorias independientes con $\mathrm{E}[A] = \mathrm{E}[B] = 0$ y $\mathrm{Var}(A) = \mathrm{Var}(B) = \sigma^2$, y $\omega \in (0, \pi)$ es una frecuencia fija.
Verificación de estacionariedad débil:

$$\begin{aligned}
\mathrm{E}[Y_t] &= \mathrm{E}[A]\cos(\omega t) + \mathrm{E}[B]\sin(\omega t) = 0. \\
\mathrm{Cov}(Y_t, Y_{t-k}) &= \mathrm{E}[Y_t Y_{t-k}] \\
&= \mathrm{E}[A^2]\cos(\omega t)\cos(\omega(t-k)) + \mathrm{E}[AB]\cos(\omega t)\sin(\omega(t-k)) \\
&\quad + \mathrm{E}[BA]\sin(\omega t)\cos(\omega(t-k)) + \mathrm{E}[B^2]\sin(\omega t)\sin(\omega(t-k)).
\end{aligned}$$

Como $\mathrm{E}[AB] = 0$ (independencia + media cero) y $\mathrm{E}[A^2] = \mathrm{E}[B^2] = \sigma^2$:

$$\mathrm{Cov}(Y_t, Y_{t-k}) = \sigma^2[\cos(\omega t)\cos(\omega(t-k)) + \sin(\omega t)\sin(\omega(t-k))] = \sigma^2\cos(\omega k),$$

donde se usó la identidad $\cos(\alpha-\beta) = \cos\alpha\cos\beta + \sin\alpha\sin\beta$. El resultado $\sigma^2\cos(\omega k)$ depende *únicamente* de $k \Rightarrow$ débilmente estacionario.
Por qué no es estrictamente estacionario en general: Cuando $t = 0$, $Y_0 = A$; cuando $t = \pi/(2\omega)$, $Y_t = B$. Si A y B tienen distribuciones distintas (e.g., $A \sim \mathcal{U}(-1,1)$, $B \sim \mathrm{Laplace}(0, 1/\sqrt{2})$, ambas con media 0 y varianza 1/3 y 1 respectivamente, ajustadas para que $\mathrm{Var}(A) = \mathrm{Var}(B)$), entonces Y_0 e Y_t tienen distribuciones marginales distintas: la distribución de la serie cambia con t aunque sus dos primeros momentos no lo hagan.

Demuestre que $|\rho(k)| \leq 1$ y que $\rho(k) = \rho(-k)$.

Respuesta 1.1(b)

Simetría $\rho(k) = \rho(-k)$.
Por la definición de covarianza y estacionariedad:

$$\gamma(k) = \mathrm{Cov}(Y_t, Y_{t-k}).$$

Intercambiando los argumentos (la covarianza es simétrica: $\mathrm{Cov}(X,Y) = \mathrm{Cov}(Y,X)$):

$$\gamma(k) = \mathrm{Cov}(Y_t, Y_{t-k}) = \mathrm{Cov}(Y_{t-k}, Y_t).$$

Hacemos el cambio de índice $s = t-k$, de modo que $t = s+k$:

$$\mathrm{Cov}(Y_s, Y_{s+k}) = \mathrm{Cov}(Y_{s+k}, Y_s).$$

Por estacionariedad, $\mathrm{Cov}(Y_s, Y_{s-(-k)}) = \gamma(-k)$, por lo tanto $\gamma(-k) = \gamma(k)$ y:

$$\rho(-k) = \frac{\gamma(-k)}{\gamma(0)} = \frac{\gamma(k)}{\gamma(0)} = \rho(k). \quad \checkmark$$

Cota $|\rho(k)| \leq 1$.
Por la *desigualdad de Cauchy-Schwarz* aplicada a las variables centradas $\tilde{Y}_t = Y_t - \mu$:

$$|\,\mathrm{E}[\tilde{Y}_t\tilde{Y}_{t-k}]|^2 \leq \mathrm{E}[\tilde{Y}_t^2]\cdot\mathrm{E}[\tilde{Y}_{t-k}^2].$$

Por estacionariedad, $\mathrm{E}[\tilde{Y}_t^2] = \mathrm{E}[\tilde{Y}_{t-k}^2] = \gamma(0)$, luego:

$$|\gamma(k)|^2 \leq \gamma(0)^2 \implies \left|\frac{\gamma(k)}{\gamma(0)}\right|^2 \leq 1 \implies |\rho(k)| \leq 1. \quad \checkmark$$

Corolario: La ACF de cualquier proceso estacionario está acotada en $[-1,1]$, que es la misma cota del coeficiente de correlación de Pearson. $\rho(k) = 1$ implica relación lineal perfecta y positiva entre Y_t e Y_{t-k}; $\rho(k) = -1$ implica relación lineal perfecta y negativa.

Sea $Y_t = 0.6Y_{t-1} + \varepsilon_t$ con $\varepsilon_t \sim \mathcal{WN}(0, \sigma^2)$. Calcule $\mathrm{Var}(Y_t)$, $\mathrm{Cov}(Y_t, Y_{t-1})$ y demuestre que $\rho(k) = 0.6^k$ para $k \geq 0$.

Respuesta 1.1(c)

Varianza. Tomando varianza a ambos lados de $Y_t = 0.6Y_{t-1} + \varepsilon_t$ y usando que Y_{t-1} y ε_t son no correlacionados (el ruido blanco es ortogonal al pasado):

$$\gamma(0) = 0.6^2\gamma(0) + \sigma^2 \implies \gamma(0)(1 - 0.36) = \sigma^2 \implies \boxed{\gamma(0) = \frac{\sigma^2}{1 - 0.6^2} = \frac{\sigma^2}{0.64}.}$$

Covarianza $\mathrm{Cov}(Y_t, Y_{t-1})$**.** Multiplicando la ecuación del proceso por Y_{t-1} y tomando esperanza:

$$\mathrm{E}[Y_t Y_{t-1}] = 0.6\,\mathrm{E}[Y_{t-1}^2] + \mathrm{E}[\varepsilon_t Y_{t-1}].$$

Como ε_t es ruido blanco, $\mathrm{E}[\varepsilon_t Y_{t-1}] = 0$ (ortogonalidad entre el choque presente y el pasado). Así:

$$\gamma(1) = 0.6\gamma(0) \implies \boxed{\mathrm{Cov}(Y_t, Y_{t-1}) = \frac{0.6\sigma^2}{0.64}.}$$

Demostración de $\rho(k) = 0.6^k$**.** Para $k \geq 1$, multiplicando la ecuación por Y_{t-k} y tomando esperanza:

$$\mathrm{E}[Y_t Y_{t-k}] = 0.6\,\mathrm{E}[Y_{t-1} Y_{t-k}] + \mathrm{E}[\varepsilon_t Y_{t-k}].$$

Como $t - k \leq t - 1 < t$, el ruido ε_t es ortogonal a Y_{t-k}, por lo que $\mathrm{E}[\varepsilon_t Y_{t-k}] = 0$. Queda:

$$\gamma(k) = 0.6\,\gamma(k-1), \quad k \geq 1.$$

Esta es la *ecuación de Yule-Walker* para AR(1). Es una recurrencia lineal de primer orden con condición inicial $\gamma(0) = \sigma^2/0.64$, cuya solución es:

$$\gamma(k) = 0.6^k\,\gamma(0) \implies \boxed{\rho(k) = \frac{\gamma(k)}{\gamma(0)} = 0.6^k, \quad k \geq 0.}$$

Nótese que $|0.6| < 1$ garantiza que $\rho(k) \to 0$ conforme $k \to \infty$, es decir, la dependencia entre Y_t e Y_{t-k} desaparece a grandes rezagos: el proceso es *ergódico* y la memoria decae exponencialmente.

Describa el patrón de ACF y PACF de un AR(1) con $\varphi > 0$, un MA(1) con $\theta > 0$, y un ruido blanco. ¿Por qué estos patrones sirven para identificar el orden del modelo?

Respuesta 1.1(d)

Definición de PACF. La función de autocorrelación parcial $\alpha(k)$ mide la correlación entre Y_t e Y_{t-k} *una vez eliminada la influencia lineal* de los valores intermedios $Y_{t-1}, \ldots, Y_{t-k+1}$. Formalmente, $\alpha(k)$ es el último coeficiente de la proyección de Hilbert $\hat{Y}_t = \sum_{j=1}^{k} \phi_j^{(k)} Y_{t-j}$: es

decir, $\alpha(k) = \phi_k^{(k)}$.

Patrones teóricos:

Modelo	**ACF** $\rho(k)$	**PACF** $\alpha(k)$
AR(1), $\varphi > 0$	Decae exponencialmente: $\rho(k) = \varphi^k > 0$	Se **corta** en rezago 1: $\alpha(1) = \varphi$, $\alpha(k) = 0$ para $k \geq 2$
MA(1), $\theta > 0$	Se **corta** en rezago 1: $\rho(1) = \theta/(1+\theta^2)$, $\rho(k) = 0$ para $k \geq 2$	Decae exponencialmente (con posibles oscilaciones)
Ruido blanco	$\rho(k) \approx 0$ para todo $k \geq 1$	$\alpha(k) \approx 0$ para todo $k \geq 1$

¿Por qué sirven para identificar el orden?
Para AR(p): La PACF mide la correlación "directa" entre Y_t e Y_{t-k}. En un AR(p), Y_t depende linealmente de $Y_{t-1}, \ldots, Y_{t-p}$ y de nada más. Para $k > p$, toda la dependencia entre Y_t e Y_{t-k} es mediada por $Y_{t-1}, \ldots, Y_{t-k+1}$; eliminada esa intermediación, la correlación parcial es exactamente cero. Por tanto, la PACF se corta en el rezago p: $\alpha(p) \neq 0$ pero $\alpha(k) = 0$ para $k > p$.
Para MA(q): $Y_t = \varepsilon_t + \theta_1\varepsilon_{t-1} + \cdots + \theta_q\varepsilon_{t-q}$ sólo comparte choques ε con Y_{t-k} cuando $k \leq q$. Para $k > q$, Y_t e Y_{t-k} usan conjuntos disjuntos de errores y por tanto $\mathrm{Cov}(Y_t, Y_{t-k}) = 0$. La ACF se corta exactamente en q.
Para ARMA(p, q): Ninguna de las dos funciones se corta abruptamente; ambas decaen de forma mixta (exponencial u oscilatoria). En la práctica, la herramienta principal de identificación pasa a ser los criterios de información AIC/BIC sobre una cuadrícula de valores (p, q).
Bandas de significancia: En muestras de tamaño T, bajo H_0 de ruido blanco, $\hat{\rho}(k) \overset{\text{aprox}}{\sim} \mathcal{N}(0, 1/T)$. La banda al 95% es $\pm 1.96/\sqrt{T}$. Se declara un rezago significativo si $|\hat{\rho}(k)| > 1.96/\sqrt{T}$.

Ejercicio 1.2 — Procesos AR, MA y ARMA

Para el AR(2): $Y_t = 1.2Y_{t-1} - 0.32Y_{t-2} + \varepsilon_t$. Calcule las raíces del polinomio $\Phi(z) = 1 - 1.2z + 0.32z^2$ y determine si el proceso es estacionario.

Respuesta 1.2(a)

Condición de estacionariedad para AR(p). El proceso ARMA(p, q) es estacionario si y sólo si todas las raíces del polinomio AR $\Phi(z) = 1 - \varphi_1 z - \cdots - \varphi_p z^p$ están *fuera* del círculo unitario, es decir, $|z_i| > 1$ para toda raíz z_i.

Cálculo de raíces. Igualando $\Phi(z) = 0$:

$$0.32z^2 - 1.2z + 1 = 0.$$

Aplicando la fórmula cuadrática:

$$z = \frac{1.2 \pm \sqrt{1.44 - 4(0.32)(1)}}{2(0.32)} = \frac{1.2 \pm \sqrt{1.44 - 1.28}}{0.64} = \frac{1.2 \pm \sqrt{0.16}}{0.64} = \frac{1.2 \pm 0.4}{0.64}.$$

$$z_1 = \frac{1.6}{0.64} = 2.5, \qquad z_2 = \frac{0.8}{0.64} = 1.25.$$

Como $|z_1| = 2.5 > 1$ y $|z_2| = 1.25 > 1$, ambas raíces están fuera del círculo unitario.

$$\boxed{\text{El proceso AR(2) es estacionario.}}$$

Interpretación. La cercanía de $z_2 = 1.25$ a la frontera del círculo unitario implica que el proceso, aunque estacionario, tiene *persistencia alta*: los choques se disipan lentamente. En términos financieros, esto se traduce en que las desviaciones respecto a la media tardan varios periodos en revertir, lo cual es relevante para estrategias de reversión a la media.

Para el MA(2): $Y_t = \varepsilon_t + 0.5\varepsilon_{t-1} - 0.3\varepsilon_{t-2}$. Calcule $\mathrm{Var}(Y_t)$, $\mathrm{Cov}(Y_t, Y_{t-1})$, $\mathrm{Cov}(Y_t, Y_{t-2})$ y $\mathrm{Cov}(Y_t, Y_{t-k})$ para $k \geq 3$.

Respuesta 1.2(b)

Para un MA(q) con $Y_t = \sum_{j=0}^{q} \theta_j \varepsilon_{t-j}$ (con $\theta_0 = 1$), la autocovarianza es:

$$\gamma(k) = \sigma^2 \sum_{j=0}^{q-k} \theta_j \theta_{j+k}, \quad 0 \leq k \leq q; \qquad \gamma(k) = 0, \quad k > q.$$

Con $\theta_0 = 1$, $\theta_1 = 0.5$, $\theta_2 = -0.3$:

Varianza ($k = 0$):

$$\gamma(0) = \sigma^2(\theta_0^2 + \theta_1^2 + \theta_2^2) = \sigma^2(1 + 0.25 + 0.09) = \boxed{1.34\,\sigma^2}.$$

$\mathrm{Cov}(Y_t, Y_{t-1})$ **($k = 1$):**

$$\gamma(1) = \sigma^2(\theta_0\theta_1 + \theta_1\theta_2) = \sigma^2(1 \cdot 0.5 + 0.5 \cdot (-0.3)) = \sigma^2(0.5 - 0.15) = \boxed{0.35\,\sigma^2}.$$

$\mathrm{Cov}(Y_t, Y_{t-2})$ **($k = 2$):**

$$\gamma(2) = \sigma^2\,\theta_0\theta_2 = \sigma^2(1)(-0.3) = \boxed{-0.3\,\sigma^2}.$$

Para $k \geq 3$: Y_t depende de $\varepsilon_t, \varepsilon_{t-1}, \varepsilon_{t-2}$ e Y_{t-k} depende de $\varepsilon_{t-k}, \varepsilon_{t-k-1}, \varepsilon_{t-k-2}$. Para $k \geq 3$, estos conjuntos son disjuntos y como los ε son no correlacionados:

$$\boxed{\gamma(k) = 0, \quad k \geq 3.}$$

Esta es la propiedad que hace identificable el orden q del MA: la ACF se corta exactamente en el rezago $q = 2$.

¿Cuándo es invertible un MA(q)? Enuncie la condición en términos de las raíces de $\Theta(z)$ y explique su importancia para el pronóstico.

Respuesta 1.2(c)

Definición de invertibilidad. Un MA(q) con $Y_t = \Theta(B)\varepsilon_t$ es *invertible* si todas las raíces del polinomio $\Theta(z) = 1 + \theta_1 z + \cdots + \theta_q z^q$ están *fuera* del círculo unitario: $|z_i| > 1$.

¿Qué implica la invertibilidad? Cuando se cumple, el proceso admite la representación AR(∞):

$$\varepsilon_t = \Theta(B)^{-1} Y_t = \sum_{j=0}^{\infty} \pi_j Y_{t-j}, \quad \text{con} \sum_{j=0}^{\infty} |\pi_j| < \infty.$$

Importancia para el pronóstico.

(i) *Recuperabilidad de los errores:* Para calcular el pronóstico óptimo de Y_{T+1}, necesitamos $\varepsilon_T, \varepsilon_{T-1}, \ldots$ Si el proceso es invertible, podemos aproximar $\varepsilon_t \approx -\sum_{j=1}^{M} \pi_j Y_{t-j}$ usando un número finito M de observaciones. Si no es invertible, los coeficientes π_j no convergen y los errores no son recuperables.

(ii) *Unicidad de la representación:* Un MA(q) no invertible tiene siempre un MA(q) invertible equivalente con la misma ACF. Exigir invertibilidad garantiza la *identificabilidad*: hay una sola parametrización canónica del proceso.

(iii) *Estabilidad numérica:* Los algoritmos de estimación (como la recursión de Kalman o el filtro de innovaciones) son numéricamente estables bajo invertibilidad.

Demuestre la representación MA(∞) de un AR(1) estacionario: si $|\varphi| < 1$, entonces $Y_t = \sum_{j=0}^{\infty} \varphi^j \varepsilon_{t-j}$.

Respuesta 1.2(d)

Demostración por sustitución recursiva. Partimos de $Y_t = \varphi Y_{t-1} + \varepsilon_t$ y sustituimos repetidamente el término Y_{t-j}:

$$\begin{aligned} Y_t &= \varepsilon_t + \varphi Y_{t-1} \\ &= \varepsilon_t + \varphi(\varepsilon_{t-1} + \varphi Y_{t-2}) \\ &= \varepsilon_t + \varphi\varepsilon_{t-1} + \varphi^2(\varepsilon_{t-2} + \varphi Y_{t-3}) \\ &= \sum_{j=0}^{n} \varphi^j \varepsilon_{t-j} + \varphi^{n+1} Y_{t-n-1}. \end{aligned}$$

El término de "cola" es $R_n = \varphi^{n+1} Y_{t-n-1}$. Para mostrar que $R_n \to 0$ en media cuadrática:

$$\mathrm{E}[R_n^2] = \varphi^{2(n+1)}\, \mathrm{E}[Y_{t-n-1}^2] = \varphi^{2(n+1)}\gamma(0) = \varphi^{2(n+1)} \frac{\sigma^2}{1-\varphi^2} \to 0$$

cuando $n \to \infty$, ya que $|\varphi| < 1$. Por tanto, el límite en media cuadrática existe y:

$$\boxed{Y_t = \sum_{j=0}^{\infty} \varphi^j \varepsilon_{t-j}.} \quad \checkmark$$

Verificación directa. Usando el operador de rezago B: $Y_t = (1-\varphi B)^{-1}\varepsilon_t$. Como $|\varphi| < 1$, la serie de potencias $(1-\varphi z)^{-1} = \sum_{j=0}^{\infty}(\varphi z)^j$ converge para $|z| \leq 1$, en particular para $z = B$, confirmando la representación.

Ejercicio 1.3 — Raíces unitarias y prueba de Dickey-Fuller

Demuestre que la caminata aleatoria $Y_t = Y_{t-1} + \varepsilon_t$ no es estacionaria calculando $\mathrm{Var}(Y_t) = t\sigma^2$ y $\mathrm{Cov}(Y_t, Y_s) = \min(s,t)\sigma^2$.

Respuesta 1.3(a)

Con $Y_0 = 0$, por sustitución recursiva:

$$Y_t = \sum_{i=1}^{t} \varepsilon_i.$$

Varianza:

$$\mathrm{Var}(Y_t) = \mathrm{Var}\left(\sum_{i=1}^{t} \varepsilon_i\right) = \sum_{i=1}^{t} \mathrm{Var}(\varepsilon_i) = t\sigma^2.$$

La varianza *crece sin límite* con t: viola la condición (ii) de estacionariedad débil.
Covarianza. Para $s \leq t$:

$$\mathrm{Cov}(Y_t, Y_s) = \mathrm{Cov}\left(\sum_{i=1}^{t} \varepsilon_i, \sum_{j=1}^{s} \varepsilon_j\right) = \sum_{i=1}^{t}\sum_{j=1}^{s} \mathrm{Cov}(\varepsilon_i, \varepsilon_j).$$

Como ε_i es ruido blanco, $\mathrm{Cov}(\varepsilon_i, \varepsilon_j) = \sigma^2 \mathbf{1}(i = j)$, por tanto:

$$\mathrm{Cov}(Y_t, Y_s) = \sigma^2 \#\{i : 1 \leq i \leq \min(s,t)\} = \min(s,t)\,\sigma^2.$$

Esta expresión depende de s y t individualmente, no sólo de $|t-s|$, violando la condición (iii). Concretamente, la *correlación* entre Y_t e Y_s es:

$$\mathrm{Corr}(Y_t, Y_s) = \frac{\min(s,t)\sigma^2}{\sqrt{t\sigma^2}\sqrt{s\sigma^2}} = \sqrt{\frac{\min(s,t)}{\max(s,t)}},$$

que tiende a 1 cuando $s/t \to 1$: observaciones cercanas en el tiempo son casi perfectamente correlacionadas. Esto es la "memoria larga" de la caminata aleatoria: no olvida su historia.

Sea $\Delta Y_t = Y_t - Y_{t-1}$. Muestre que $\Delta Y_t = \varepsilon_t$ para la caminata aleatoria.

Respuesta 1.3(b)

$$\Delta Y_t = Y_t - Y_{t-1} = (Y_{t-1} + \varepsilon_t) - Y_{t-1} = \varepsilon_t. \quad \checkmark$$

La primera diferencia de una caminata aleatoria es ruido blanco, que es $I(0)$ (estacionario). Por eso se dice que la caminata aleatoria es $I(1)$: integrada de orden 1. En finanzas, si $y_t = \log P_t$ sigue una caminata aleatoria, entonces $r_t = \Delta y_t$ son los log-retornos: ruido blanco (lo que constituye la hipótesis de mercados eficientes en su forma débil).

La prueba ADF contrasta $H_0 : \delta = 0$ en $\Delta Y_t = \mu + \delta Y_{t-1} + \sum_{j=1}^{k} \psi_j \Delta Y_{t-j} + \varepsilon_t$. Explique por qué bajo H_0 el estadístico de $\hat{\delta}$ no sigue una distribución t clásica.

Respuesta 1.3(c)

El problema fundamental. La teoría asintótica estándar de MCO requiere que los regresores sean $I(0)$ (estacionarios). Cuando el regresor es $I(1)$, la teoría de grandes muestras usual se rompe.

Bajo $H_0 : \delta = 0$, Y_{t-1} es una caminata aleatoria, es decir $I(1)$. Su varianza muestral $T^{-1} \sum Y_{t-1}^2$ diverge a razón de T, lo que altera las propiedades asintóticas del estimador MCO:

(i) *Velocidad de convergencia supereficiente:* $\hat{\delta}$ converge a $\delta = 0$ a tasa T (no $\sqrt{T}$). El estimador es "superconsistente" pero su distribución límite no es normal.

(ii) *Distribución límite no estándar:* El estadístico $t_{\hat{\delta}} = \hat{\delta}/\mathrm{se}(\hat{\delta})$ converge a la distribución de Dickey-Fuller:

$$t_{\hat{\delta}} \xrightarrow{d} \frac{\int_0^1 W(r)\, dW(r)}{\left(\int_0^1 W(r)^2\, dr\right)^{1/2}},$$

donde $W(r)$ es un movimiento browniano estándar. Esta distribución es asimétrica hacia la izquierda y más negativa que la distribución t estándar.

(iii) *Consecuencia práctica:* Si se usaran los valores críticos de la distribución t clásica, se rechazaría H_0 (raíz unitaria) con demasiada frecuencia, concluyendo falsamente que la serie es estacionaria. Los valores críticos de Dickey-Fuller (tabulados por simulación) son mucho más negativos: e.g., al 5% con constante, el valor crítico es aproximadamente -2.86 (vs. -1.65 de la t clásica).

En finanzas, los log-precios suelen ser $I(1)$ y los log-retornos $I(0)$. Explique la diferencia y su implicación para el modelado y la predicción.

Respuesta 1.3(d)

Log-precio $y_t = \log P_t \sim I(1)$. Tiene una raíz unitaria: su varianza crece con t y no existe una media de largo plazo a la que regrese. Modelar directamente y_t con ARMA produciría *regresión espuria*: dos series $I(1)$ independientes pueden mostrar alta R^2 y t-estadísticos grandes sin que exista relación causal.

Log-retorno $r_t = \Delta y_t = \log(P_t/P_{t-1}) \sim I(0)$. Es la tasa de variación porcentual del precio. Tiene media y varianza finitas y estables; la inferencia estadística (intervalos de confianza, pruebas t) es válida.

Dimensión	**Log-precio** $y_t \sim I(1)$	**Log-retorno** $r_t \sim I(0)$
Modelado	No directamente (regresión espuria)	ARMA(p, q) o GARCH
Pronóstico	Intervalo crece como $\sqrt{h}$	Intervalo converge a varianza incondicional
Regresión	Espuria si no hay cointegración	Inferencia válida
Reversión a media	No ("vaga" sin ancla)	Sí (fluctúa alrededor de μ)
Interpretación	Precio en escala log	Rendimiento continuo

Implicación para Value-at-Risk. El horizonte de pronóstico importa: para un VaR a 10 días, la volatilidad del log-precio crece como $\sigma\sqrt{10}$ (porque la varianza acumula), mientras que la volatilidad del retorno diario σ es estable. Los modelos de riesgo operan con retornos, no con precios.

Resumen de integración. Una serie X_t es $I(d)$ si requiere diferenciarse d veces para volverse estacionaria: $\Delta^d X_t \sim I(0)$. En la práctica financiera: log-precios $\sim I(1)$, spreads de cointegración $\sim I(0)$, volatilidad realizada $\sim I(d)$ con $d \in (0, 1)$ ("larga memoria", modelos ARFIMA).

2. Modelos ARIMA(p, d, q)

Ejercicio 2.1 — Identificación, estimación y diagnóstico

Para cada patrón hipotético de ACF y PACF, identifique el orden del modelo: (i) ACF decae exponencialmente; PACF se corta en rezago 2. (ii) ACF se corta en rezago 1; PACF decae. (iii) Ambas decaen sin cortarse. (iv) ACF tiene pico significativo sólo en rezago 1.

Respuesta 2.1(a)

(i) ACF decae exponencialmente; PACF se corta en rezago 2 $\Rightarrow$ **AR(2)**. La PACF se anula para $k > p = 2$; la ACF hereda el decaimiento geométrico (o en espiral si hay raíces complejas) del polinomio AR.

(ii) ACF se corta en rezago 1; PACF decae $\Rightarrow$ **MA(1)**. La ACF es nula para $k > q = 1$; la PACF decae porque la representación AR(∞) del MA(1) tiene infinitos términos.

(iii) Ambas decaen sin corte abrupto $\Rightarrow$ **ARMA**(p, q) con $p \geq 1$ y $q \geq 1$. La superposición de componentes AR y MA genera decaimientos mixtos en ambas funciones. Se requieren los criterios AIC/BIC para determinar los órdenes exactos.

(iv) ACF con pico significativo *sólo* en rezago 1, cero después $\Rightarrow$ **MA(1)**. Es el mismo diagnóstico que (ii): el corte en la ACF es la firma del MA.

Regla mnemotécnica: "AR corta PACF, MA corta ACF." Esto es consecuencia directa de la dualidad entre las representaciones AR(∞) y MA(∞).

Explique los criterios AIC y BIC. ¿Cuál penaliza más la complejidad y en qué condición sobre n?

Respuesta 2.1(b)

Ambos criterios tienen la forma: bondad de ajuste − penalización por complejidad.

$$\text{AIC} = -2\log\hat{L} + 2k, \qquad \text{BIC} = -2\log\hat{L} + k\log n,$$

donde $\hat{L}$ es la verosimilitud maximizada, k el número de parámetros libres y n el tamaño de muestra. Se selecciona el modelo con *menor* criterio.

Comparación de penalizaciones:

- AIC penaliza $+2$ por parámetro adicional.
- BIC penaliza $+\log n$ por parámetro adicional.
- BIC penaliza más cuando $\log n > 2$, es decir, $n > e^2 \approx 7.4$.

Propiedades asintóticas:

- *AIC* es *eficiente*: minimiza el error de predicción fuera de muestra (bajo supuestos regulares, minimiza la divergencia de Kullback-Leibler entre el modelo verdadero y el ajustado). Tiende a sobreajustar para n grande.
- *BIC* es *consistente*: bajo condiciones estándar, selecciona el modelo verdadero con probabilidad $\to 1$ cuando $n \to \infty$. Es más conservador (parsimoniosas).

Recomendación práctica: Si el objetivo es *predicción*, usar AIC. Si el objetivo es *inferencia sobre la estructura del proceso verdadero*, usar BIC. Para series financieras con n grande (≥ 250), BIC puede ser muy restrictivo y AIC suele dar mejor cobertura en los intervalos de predicción.

Describa el procedimiento de Box-Jenkins en tres etapas. ¿Qué gráficas se inspeccionan en cada etapa?

Respuesta 2.1(c)

El procedimiento de Box-Jenkins (1970) es el marco estándar para ajustar modelos ARIMA. Consta de tres etapas iterativas:

Etapa 1 — Identificación.

- Graficar la serie Y_t vs. t: detectar tendencia, cambios de nivel, cambios de varianza y estacionalidad.
- Graficar la ACF y PACF muestrales: usar los patrones teóricos para proponer órdenes p y q candidatos.
- Prueba ADF (o KPSS) para determinar el orden de integración d: si $Y_t \sim I(1)$, tomar ΔY_t y repetir.
- Si hay heterocedasticidad (varianza creciente), aplicar $\log(Y_t)$ o Box-Cox antes de proceder.

Etapa 2 — Estimación.

- Estimar los parámetros $(\varphi_1, \ldots, \varphi_p, \theta_1, \ldots, \theta_q, \sigma^2)$ por Máxima Verosimilitud Condicional o Exacta.
- Comparar modelos candidatos con AIC/BIC sobre una cuadrícula de órdenes (p, q).
- Verificar que los estimadores sean estadísticamente significativos (intervalos de confianza que no contengan cero).

Etapa 3 — Diagnóstico.

- Graficar los residuos $\hat{\varepsilon}_t$: deben parecer ruido blanco (sin estructura visible, sin heterocedasticidad).
- ACF y PACF de los residuos: no debe haber picos fuera de las bandas de significancia.
- Prueba de Ljung-Box: confirma formalmente si los residuos son ruido blanco.
- Histograma y Q-Q plot de residuos: verificar normalidad (o al menos ausencia de curtosis extrema).
- Si el diagnóstico falla: regresar a la Etapa 1 con un orden mayor o con transformaciones adicionales.

Enuncie la prueba de Ljung-Box y explique cómo usarla con $h = \min(10, n/5)$ rezagos para diagnosticar residuos.

Respuesta 2.1(d)

Enunciado. Sea $\hat{\varepsilon}_t$ el residuo del modelo ARIMA(p, d, q) ajustado. El estadístico de Ljung-Box es:

$$Q(h) = n(n+2)\sum_{k=1}^{h} \frac{\hat{\rho}_k^2}{n-k},$$

donde $\hat{\rho}_k$ es la autocorrelación muestral de los residuos en el rezago k. Bajo H_0 (los residuos son ruido blanco):

$$Q(h) \overset{a}{\sim} \chi^2(h-p-q).$$

Se usan $h-p-q$ grados de libertad en lugar de h porque estimar $p+q$ parámetros "absorbe" parte de la variación en las autocorrelaciones.

Criterio $h = \min(10, n/5)$. Este valor de h es un compromiso: suficientemente grande para detectar correlación serial en rezagos medianos, pero no tan grande que el estadístico pierda potencia por acumular rezagos con muy poca información.

Procedimiento:

1. Ajustar ARIMA(p, d, q) y obtener residuos $\hat{\varepsilon}_t$.
2. Calcular $h = \min(10, n/5)$.
3. Calcular $Q(h)$ y comparar con $\chi^2_{1-\alpha,\, h-p-q}$.
4. Si $Q(h) >$ valor crítico (o p-valor $< \alpha$): rechazar $H_0 \Rightarrow$ residuos tienen estructura $\Rightarrow$ modelo mal especificado.
5. Si $Q(h) \leq$ valor crítico: no rechazar $H_0 \Rightarrow$ residuos compatibles con ruido blanco $\Rightarrow$ modelo adecuado.

Limitación importante: La prueba de Ljung-Box no detecta heterocedasticidad condicional (efectos ARCH). Aunque los residuos sean no autocorrelacionados en nivel, pueden tener autocorrelación en $\hat{\varepsilon}_t^2$. En finanzas, siempre complementar con la prueba de Engle (LM-ARCH) sobre los residuos al cuadrado.

Ejercicio 2.2 — ARIMA(1,1,1) para log-precios

Sea $r_t = \Delta y_t$. Muestre que el ARIMA(1,1,1) se convierte en un ARMA(1,1) para r_t y escriba la ecuación explícitamente.

Respuesta 2.2(a)

El modelo ARIMA(1,1,1) es:

$$(1-\varphi_1 B)(1-B)y_t = (1+\theta_1 B)\varepsilon_t.$$

Definiendo $r_t = \Delta y_t = (1-B)y_t$, el operador $(1-B)$ actúa primero sobre y_t dando r_t:

$$(1-\varphi_1 B)r_t = (1+\theta_1 B)\varepsilon_t.$$

Expandiendo los operadores de rezago:

$$r_t - \varphi_1 r_{t-1} = \varepsilon_t + \theta_1 \varepsilon_{t-1}.$$

$$\boxed{r_t = \varphi_1 r_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1}.}$$

Este es un ARMA(1,1) para los log-retornos r_t. La componente AR(1) captura la posible autocorrelación de primer orden en los retornos (e.g., microestructura de mercado, rebalanceos); la componente MA(1) captura el efecto de noticias o choques que impactan el retorno actual y el siguiente.

Con $\hat{\varphi}_1 = 0.15$ y $\hat{\theta}_1 = -0.08$, calcule $\hat{r}_{T+1|T}$. Construya el IC al 95% para r_{T+1} y tradúzcalo a un intervalo para $P_{T+1} = P_T e^{r_{T+1}}$.

Respuesta 2.2(b) y (c)

Pronóstico puntual. El pronóstico óptimo (mínimo ECM lineal) del ARMA(1,1) un paso adelante es:

$$\hat{r}_{T+1|T} = \mathrm{E}[r_{T+1} \mid r_T, r_{T-1}, \ldots] = \varphi_1 r_T + \theta_1 \varepsilon_T.$$

En la práctica, ε_T se aproxima por el residuo del modelo al tiempo T. En la forma expandida que usa la recursión de innovaciones:

$$\boxed{\hat{r}_{T+1|T} = 0.15\, r_T - 0.08\, \hat{\varepsilon}_T.}$$

El ECM a un paso es simplemente σ^2 (varianza del ruido blanco), ya que $r_{T+1} - \hat{r}_{T+1|T} = \varepsilon_{T+1}$.

Intervalo de predicción al 95% para r_{T+1}:

$$\hat{r}_{T+1|T} \pm 1.96\hat{\sigma}.$$

Traducción a P_{T+1}. Como $r_{T+1} = \log P_{T+1} - \log P_T$, entonces $P_{T+1} = P_T e^{r_{T+1}}$. Aplicando la función monótona $x \mapsto P_T e^x$ a los extremos del intervalo:

$$\boxed{P_{T+1} \in \left[P_T\, e^{\hat{r}_{T+1|T} - 1.96\hat{\sigma}}, \quad P_T\, e^{\hat{r}_{T+1|T} + 1.96\hat{\sigma}}\right].}$$

Obsérvese que este intervalo es *asimétrico* en escala de precios: la distancia del extremo superior al pronóstico central ($P_T e^{\hat{r}}(e^{1.96\hat{\sigma}} - 1)$) es mayor que la distancia al extremo inferior ($P_T e^{\hat{r}}(1 - e^{-1.96\hat{\sigma}})$). Esto es coherente con el hecho de que los precios son no negativos y log-normalmente distribuidos: la ganancia potencial supera en magnitud a la pérdida máxima (que está acotada por P_T).

¿El ARIMA(1,1,1) captura el efecto de asimetría en volatilidad? ¿Qué extensión sería necesaria?

Respuesta 2.2(d)

No. El ARIMA(1,1,1) supone $\varepsilon_t \sim \mathcal{WN}(0, \sigma^2)$ con varianza *constante* e independiente del signo de los retornos pasados. Por construcción, no puede capturar el *efecto apalancamiento* (leverage effect): el fenómeno empírico por el cual una caída del precio genera más volatilidad que una subida de igual magnitud.

Evidencia del efecto apalancamiento. Black (1976) y Christie (1982) documentaron que la correlación entre r_t y σ^2_{t+1} es negativa: cuando el precio cae, el valor de la empresa cae pero la deuda permanece, aumentando el apalancamiento y por tanto el riesgo. Nelson (1991) formalizó esto con el modelo **EGARCH**:

$$\log \sigma_t^2 = \omega + \beta \log \sigma_{t-1}^2 + \alpha \left| \frac{\varepsilon_{t-1}}{\sigma_{t-1}} \right| + \gamma \frac{\varepsilon_{t-1}}{\sigma_{t-1}},$$

donde $\gamma < 0$ captura la asimetría: un choque negativo ($\varepsilon_{t-1} < 0$) aumenta la volatilidad más que uno positivo. Alternativamente, el modelo **GJR-GARCH** (Glosten-Jagannathan-Runkle, 1993):

$$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \gamma \varepsilon_{t-1}^2 \mathbf{1}(\varepsilon_{t-1} < 0) + \beta \sigma_{t-1}^2.$$

Si $\gamma > 0$, los retornos negativos generan mayor volatilidad futura que los positivos.

Implicación para gestión de riesgo. Un modelo que ignora la asimetría subestima el VaR en periodos bajistas: precisamente cuando más importa tener una buena estimación del riesgo. Los modelos EGARCH/GJR-GARCH con distribución t-Student o GED para $z_t = \varepsilon_t/\sigma_t$ son el estándar industrial.

Ejercicio 2.3 — Pronóstico con ARIMA(2,1,0)

Sea $\{Y_t\}$ un proceso ARIMA(2,1,0): $(1-0.5B+0.2B^2)(1-B)Y_t = \varepsilon_t$ con $\sigma^2 = 1$. Con $Y_T = 100$, $W_T = 1.2$, $W_{T-1} = 0.8$ donde $W_t = \Delta Y_t$: (a) escriba el AR(2) para W_t; (b) calcule $\hat{W}_{T+1|T}$ y $\hat{W}_{T+2|T}$; (c) calcule ψ_0, ψ_1, ψ_2 y los ECM; (d) construya los IC al 95% para W_{T+1}, W_{T+2} y tradúzcalos a Y_{T+1}, Y_{T+2}.

Respuesta 2.3

(a) Definiendo $W_t = \Delta Y_t$:

$$\boxed{W_t = 0.5W_{t-1} - 0.2W_{t-2} + \varepsilon_t.}$$

(b) Pronósticos.

$$\hat{W}_{T+1|T} = 0.5(1.2) - 0.2(0.8) = 0.6 - 0.16 = \mathbf{0.44}.$$

Para $h = 2$, los errores futuros tienen esperanza condicional cero:

$$\hat{W}_{T+2|T} = 0.5\hat{W}_{T+1|T} - 0.2W_T = 0.5(0.44) - 0.2(1.2) = 0.22 - 0.24 = -\mathbf{0.02}.$$

(c) Coeficientes MA(∞) y ECM. La representación MA(∞) de un AR(p) tiene coeficientes ψ_j que satisfacen la recurrencia $\psi_j = \sum_{k=1}^{p} \varphi_k \psi_{j-k}$ con $\psi_0 = 1$:

$$\psi_0 = 1, \quad \psi_1 = \varphi_1 = 0.5, \quad \psi_2 = \varphi_1\psi_1 + \varphi_2\psi_0 = 0.25 - 0.20 = 0.05.$$

El ECM a horizonte h para los retornos W_t:

$$\text{MSE}_1 = \sigma^2\psi_0^2 = 1(1) = \mathbf{1.00}, \quad \text{MSE}_2 = \sigma^2(\psi_0^2 + \psi_1^2) = 1(1 + 0.25) = \mathbf{1.25}.$$

(d) Intervalos de predicción al 95%.
Para W_{T+1}: $0.44 \pm 1.96\sqrt{1.00} = 0.44 \pm 1.96 = [\mathbf{-1.52},\ \mathbf{2.40}]$.
Para W_{T+2}: $-0.02 \pm 1.96\sqrt{1.25} = -0.02 \pm 2.19 = [\mathbf{-2.21},\ \mathbf{2.17}]$.
Traducción a Y usando $Y_{T+h} = Y_T + \sum_{j=1}^{h} W_{T+j}$:

$$\hat{Y}_{T+1} = 100 + 0.44 = 100.44, \quad Y_{T+1} \in [98.48,\ 102.40].$$

$$\hat{Y}_{T+2} = 100 + 0.44 + (-0.02) = 100.42, \quad Y_{T+2} \in [98.23,\ 102.61].$$

Obsérvese que MSE_h es creciente: $\psi_j^2 \geq 0$ para todo j, por lo que cada horizonte adicional añade varianza. El intervalo para Y_{T+2} es más amplio que el de Y_{T+1}, reflejando la incertidumbre acumulada.

Ejercicio 2.4 — Cointegración y spreads estadísticos

(a) Enuncie el teorema de Granger y explique el término de corrección de error. (b) ¿Cómo estimar β y verificar cointegración? (c) Si el spread sigue AR(1), calcule media, varianza y tiempo de retorno. (d) Para $\varphi = 0.95$, $\mu = 0$, $\sigma = 0.01$: calcule estadísticas y regla de trading.

Respuesta 2.4

(a) Teorema de representación de Granger. Si Y_t y X_t son $I(1)$ y cointegrados con vector $(1, -\beta)$, entonces existe una representación de Corrección de Error (ECM o VEC):

$$\Delta Y_t = \underbrace{\alpha(Y_{t-1} - \beta X_{t-1})}_{\text{corrección de error}} + \sum_j \gamma_j \Delta Y_{t-j} + \sum_j \delta_j \Delta X_{t-j} + \varepsilon_t.$$

El término $\alpha(Y_{t-1} - \beta X_{t-1})$ es la *fuerza restauradora*: mide el desequilibrio del periodo anterior respecto al equilibrio de largo plazo $Y_t = \beta X_t$. El parámetro $\alpha < 0$ implica que cuando $Y_{t-1} > \beta X_{t-1}$ (sistema por encima del equilibrio), ΔY_t se vuelve negativo, empujando la relación de regreso. La velocidad de ajuste $|\alpha|$ mide cuánta fracción del desequilibrio se corrige cada periodo: $|\alpha| = 0.2$ significa que el 20% del desequilibrio se corrige en un periodo.

(b) Procedimiento de Engle-Granger (1987).

1. MCO de largo plazo: $Y_t = \hat{\alpha} + \hat{\beta} X_t + \hat{Z}_t$. El estimador MCO de β es superconsistente ($\hat{\beta} \xrightarrow{p} \beta$ a tasa T).
2. Obtener residuos $\hat{Z}_t = Y_t - \hat{\beta} X_t$.
3. Aplicar prueba ADF sobre $\hat{Z}_t$ con valores críticos de Engle-Granger (más negativos que los de DF estándar porque $\hat{Z}_t$ usa parámetros estimados). Si se rechaza $H_0 \Rightarrow$ cointegración confirmada.

(c) AR(1) para el spread: $Z_t = \mu + \varphi Z_{t-1} + \varepsilon_t$.

Por estacionariedad ($\mathrm{E}[Z_t] = \mathrm{E}[Z_{t-1}]$):

$$\mathrm{E}[Z_t] = \frac{\mu}{1-\varphi}, \quad \mathrm{Var}(Z_t) = \frac{\sigma^2}{1-\varphi^2}, \quad \mathrm{E}[\tau_\mu] = \frac{1}{1-\varphi}.$$

El tiempo de retorno $\mathrm{E}[\tau_\mu]$ es el número esperado de periodos para que el spread regrese a su media, análogo al tiempo de vida media de un proceso de Ornstein-Uhlenbeck en tiempo continuo.

(d) $\varphi = 0.95$, $\mu = 0$, $\sigma = 0.01$.

$$\mathrm{E}[Z_t] = 0, \quad \mathrm{SD}(Z_t) = \sqrt{\frac{(0.01)^2}{1-0.9025}} = \sqrt{\frac{0.0001}{0.0975}} \approx 0.0320, \quad \mathrm{E}[\tau_\mu] = 20.$$

Regla de trading (bandas de Bollinger del spread):

Condición	Posición	Lógica
$Z_t > +2 \cdot \mathrm{SD} \approx +0.064$	Corto Y, largo X (vender spread)	Spread revertirá a la baja
$Z_t < -2 \cdot \mathrm{SD} \approx -0.064$	Largo Y, corto X (comprar spread)	Spread revertirá al alza
$\lvert Z_t \rvert < 1 \cdot \mathrm{SD}$	Cerrar posición	Spread cerca del equilibrio

Riesgos clave: (i) *Ruptura de cointegración*: si la relación estructural cambia (fusión, regulación, cambio tecnológico), el spread puede no revertir. (ii) *Persistencia*: con $\varphi = 0.95$, el spread puede mantenerse alejado del equilibrio 20 periodos; las pérdidas mark-to-market pueden generar llamadas de margen antes de que se produzca la convergencia. (iii) *Bid-ask spread y costos de transacción*: en la práctica, la señal debe superar al menos 3 SD para ser rentable neta de costos.

3. Modelos SARIMA y estacionalidad

Ejercicio 3.1 — Estructura y notación SARIMA

Para datos mensuales ($s = 12$), escriba explícitamente el modelo SARIMA$(1,1,1)(1,1,1)_{12}$. Calcule $\Delta_{12}(\Delta_1 Y_t)$ en términos de rezagos de Y_t.

Respuesta 3.1(a) y (b)

(a) El modelo SARIMA$(1,1,1)(1,1,1)_{12}$ es:

$$\underbrace{(1-\Phi_1 B^{12})}_{\text{AR estacional}}\underbrace{(1-\varphi_1 B)}_{\text{AR regular}}\underbrace{(1-B^{12})}_{\Delta_s}\underbrace{(1-B)}_{\Delta} Y_t = \underbrace{(1+\Theta_1 B^{12})}_{\text{MA estacional}}\underbrace{(1+\theta_1 B)}_{\text{MA regular}}\varepsilon_t.$$

(b) Expandiendo los operadores de diferenciación:

$$\begin{aligned}(1-B)(1-B^{12})Y_t &= (1-B-B^{12}+B^{13})Y_t \\ &= \boxed{Y_t - Y_{t-1} - Y_{t-12} + Y_{t-13}.}\end{aligned}$$

Este operador es la "doble diferencia" que elimina simultáneamente la tendencia estocástica (vía Δ) y la estacionalidad estocástica (vía Δ_{12}). El resultado involucra cuatro rezagos: el actual, el periodo anterior, el mismo mes del año anterior y el mes anterior del año anterior.

¿Qué patrones ACF sugieren necesidad de Δ_{12}? ¿Qué combinación (d, D) es apropiada para ventas minoristas mensuales?

Respuesta 3.1(c) y (d)

(c) Diagnóstico de necesidad de Δ_{12}.
Antes de Δ_{12}: la ACF muestral presenta picos *grandes y persistentes* en $k = 12, 24, 36, \ldots$ que decaen muy lentamente (casi no disminuyen de un múltiplo al siguiente). Esto es la firma de una raíz unitaria estacional: el proceso tiene una "memoria de un año" que no se disipa.

	$\hat{\rho}(12)$	$\hat{\rho}(24)$	$\hat{\rho}(36)$
Antes de Δ_{12}	≈ 0.80	≈ 0.65	≈ 0.55 (lento)
Después de Δ_{12}	< 0.3	≈ 0	≈ 0

(d) Combinación (d, D) para ventas minoristas mensuales.
La combinación estándar es $\mathbf{d = 1, D = 1}$:

- $d = 1$: las ventas tienen tendencia de largo plazo (crecimiento secular), que es estocástica ($I(1)$). Una diferencia regular la elimina.
- $D = 1$: la estacionalidad es estocástica (la amplitud del ciclo navideño varía año a año). Una diferencia estacional la elimina.
- Parsimonia: $d + D \leq 2$ es el límite empírico; sobrediferenciar introduce raíces unitarias

MA innecesarias que complican la estimación y empeoran el pronóstico.

Ejercicio 3.2 — Modelo de Airline

Para el modelo SARIMA$(0,1,1)(0,1,1)_{12}$ ajustado a ventas V_t: (a) expanda ambos lados; (b) escriba la ecuación completa; (c) con $\hat{\theta}_1 = -0.4$, $\hat{\Theta}_1 = -0.6$ y datos dados, calcule $\hat{V}_{61}$; (d) explique por qué los intervalos crecen con el horizonte.

Respuesta 3.2

(a) Lado izquierdo:

$$(1-B)(1-B^{12})V_t = V_t - V_{t-1} - V_{t-12} + V_{t-13}.$$

(b) Lado derecho:

$$(1+\theta_1 B)(1+\Theta_1 B^{12})\varepsilon_t = \varepsilon_t + \theta_1\varepsilon_{t-1} + \Theta_1\varepsilon_{t-12} + \theta_1\Theta_1\varepsilon_{t-13}.$$

Ecuación completa:

$$V_t = V_{t-1} + V_{t-12} - V_{t-13} + \varepsilon_t + \theta_1\varepsilon_{t-1} + \Theta_1\varepsilon_{t-12} + \theta_1\Theta_1\varepsilon_{t-13}.$$

(c) Pronóstico $\hat{V}_{61}$. Con $V_{60} = 50$, $V_{48} = 40$, $V_{47} = 35$, $\hat{\varepsilon}_{60} = 2$, $\hat{\varepsilon}_{48} = 1$ y usando $V_{49} \approx V_{48} + (V_{48} - V_{47}) = 45$ (aproximación de tendencia lineal):

$$\hat{V}_{61} = V_{60}+V_{48}-V_{47}+\hat{\theta}_1\hat{\varepsilon}_{60}+\hat{\Theta}_1\hat{\varepsilon}_{48} = 50+40-35+(-0.4)(2)+(-0.6)(1) = 55-0.8-0.6 = \boxed{53.6 \text{ millones MXN.}}$$

(d) Por qué los intervalos crecen. El ECM a horizonte h es:

$$\mathrm{MSE}_h = \sigma^2 \sum_{j=0}^{h-1} \psi_j^2,$$

donde ψ_j son los coeficientes de la representación MA(∞) del modelo. Como $\psi_j^2 \geq 0$, la suma es monótonamente creciente en h: cada periodo adicional agrega la varianza del error ε_{T+j} que no puede predecirse. Para $h = 1$, sólo se desconoce ε_{T+1}; para $h = 13$ (predicción al año siguiente), se desconocen $\varepsilon_{T+1}, \ldots, \varepsilon_{T+13}$, y toda esa incertidumbre se acumula. En el límite $h \to \infty$, el intervalo converge al intervalo incondicional de la distribución estacionaria del proceso.

Ejercicio 3.3 — SARIMA para CETES

Tasas de CETES a 28 días, semanales, con ciclo trimestral $s = 13$. (a) Proponga SARIMA y argumente órdenes. (b) Pronóstico 4 semanas con IC al 80% y 95%. (c) ECMP vs. ARIMA sin estacionalidad. (d) Regla de decisión para trading de tasas.

Respuesta 3.3

(a) Propuesta: $\mathbf{SARIMA}(1,1,0)(1,1,0)_{13}$.
Argumentación: Las tasas de interés son generalmente $I(1)$ con drift estocástico ($d = 1$). Existe un ciclo fiscal trimestral ligado a vencimientos y subastas ($D = 1$, $s = 13$). La PACF muestral muestra un pico en $k = 1$ (componente AR regular, $p = 1$) y un pico en $k = 13$ (componente AR estacional, $P = 1$). Sin picos significativos en la ACF a rezagos no múltiplos de 13 ni en la PACF para $k > 1$ (excluyendo múltiplos de 13), por lo que $q = Q = 0$.
(b) Intervalos de predicción:

$$\hat{r}_{T+h|T} \pm z_\alpha \hat{\sigma} \sqrt{\sum_{j=0}^{h-1} \psi_j^2}, \quad z_{0.80} = 1.282,\ z_{0.95} = 1.960.$$

(c) ECMP $= \frac{1}{26}\sum(\hat{r}_{T+h} - r_{T+h})^2$ en las últimas 26 semanas. El SARIMA debería superar al ARIMA$(1,1,0)$ si el ciclo trimestral tiene poder predictivo real. Si $\text{ECMP}_{\text{SARIMA}} < \text{ECMP}_{\text{ARIMA}}$ y el BIC del SARIMA también es menor, el componente estacional se justifica.
(d) Regla de decisión.

Condición	Acción	Fundamento
$\text{LI}_{95\%} > r_{\text{forward}}$	Comprar futuros CETES	Toda la distribución predictiva supera el forward
$\text{LS}_{95\%} < r_{\text{forward}}$	Vender futuros CETES	Toda la distribución predictiva está por debajo
IC cruza r_{forward}	No operar	Señal ambigua; riesgo de modelo elevado

Riesgo de modelo: Con un modelo mal especificado o ante una decisión sorpresiva de Banxico, el pronóstico puede fallar catastróficamente. Es prudente escalar el tamaño de la posición inversamente proporcional a la anchura del IC.

Ejercicio 3.4 — Descomposición STL

(a) Ventajas de STL frente a descomposición clásica y X-12-ARIMA. (b) Serie desestacionalizada con $T_t = 2 + 0.1t$, $S_t = 3\sin(2\pi t/12)$. (c) STL+ARIMA vs. ARIMA directo en commodities. (d) Interprete el indicador de fuerza estacional FS.

Respuesta 3.4

(a) Ventajas de STL. STL (Seasonal-Trend decomposition using LOESS, Cleveland et al., 1990) supera a los métodos clásicos en tres dimensiones:

(i) *Robustez ante atípicos:* STL usa regresión LOESS (localmente ponderada), que asigna pesos bajos a observaciones outlier. La descomposición clásica y X-12 son sensibles a valores extremos.

(ii) *Componente estacional variable:* STL permite que la amplitud y forma del patrón estacional evolucionen con el tiempo (ancho de ventana n_s controla la suavidad). Los métodos clásicos asumen estacionalidad fija.

(iii) *Flexibilidad:* STL funciona con cualquier frecuencia s (horaria, semanal, quincenal), mientras X-12 fue diseñado para datos mensuales/trimestrales.

(b) Con $Y_t = T_t + S_t + R_t$, $T_t = 2 + 0.1t$, $S_t = 3\sin(2\pi t/12)$:

$$Y_t^{\text{des}} = Y_t - S_t = T_t + R_t = 2 + 0.1t + R_t.$$

El ARIMA se ajusta sobre Y_t^{des}: modela la dinámica de R_t sin que la periodicidad de S_t contamine los parámetros AR/MA.

(c) STL+ARIMA vs. ARIMA directo. En el gas natural, la estacionalidad invernal cambia de amplitud año a año (demanda alta en inviernos fríos vs. templados). STL captura esto con una ventana adaptativa. El ARIMA directo asume implícitamente una estacionalidad fija o modela con dummies, que no se adaptan. Además, los picos de precio por tormentas (atípicos) no distorsionan el STL. El pronóstico final recombina $\hat{Y}_{T+h} = \hat{T}_{T+h} + \hat{S}_{T+h} + \hat{R}_{T+h}$, donde cada componente tiene su propia incertidumbre.

(d) $FS = \max\left\{0,\, 1 - \dfrac{\text{Var}(R_t)}{\text{Var}(S_t + R_t)}\right\}$.

$FS \approx 0$: $\text{Var}(R_t) \approx \text{Var}(S_t + R_t) \Rightarrow$ la estacionalidad es débil o nula; aplicar SARIMA añade complejidad sin beneficio.

$FS \approx 1$: $\text{Var}(R_t) \ll \text{Var}(S_t + R_t) \Rightarrow$ casi toda la variación no-tendencial viene del componente estacional; el SARIMA es indispensable y el residuo es poco variable (bien modelado).

4. Modelos SARIMAX con variables exógenas

Ejercicio 4.1 — ARIMAX

(a) Diferencia entre ARIMAX y regresión clásica con errores correlacionados. (b) ARIMAX$(1,1,0)$ para tipo de cambio MXN/USD. (c) Condiciones de estacionariedad del ARMAX. (d) Comparación AIC/BIC para selección de variable exógena.

Respuesta 4.1

(a) En regresión clásica $Y_t = \beta^\top x_t + u_t$ con $u_t \sim i.i.d.$, si u_t es en realidad ARMA, MCO sigue siendo insesgado pero:

(i) Es *ineficiente*: el estimador GLS (o MV) tiene menor varianza. Gauss-Markov no aplica con errores correlacionados.

(ii) Los *errores estándar de MCO son incorrectos*: el estimador de varianza $s^2(X^\top X)^{-1}$ asume $\mathrm{Cov}(u) = \sigma^2 I$. Con autocorrelación, $\mathrm{Cov}(u) \neq \sigma^2 I$ y los estadísticos t y F son inválidos.

(iii) El *pronóstico es subóptimo*: ignora la estructura de correlación de los errores, que contiene información adicional.

En ARIMAX, se modela $u_t = \theta_q(B)\varepsilon_t$ conjuntamente con el efecto de x_t, obteniendo estimadores eficientes e inferencia válida.

(b) Con $Y_t = \log(\mathrm{MXN/USD})$ y $x_t = i_{\mathrm{MX},t} - i_{\mathrm{US},t}$ (diferencial de tasas):

$$(1-\varphi_1 B)(1-B)Y_t = \beta\, x_t + \varepsilon_t.$$

Por la *paridad descubierta de tasas de interés (UIP)*: mayor diferencial de tasas $\Rightarrow$ mayor demanda de activos en pesos $\Rightarrow$ apreciación del peso $\Rightarrow$ caída del tipo de cambio. Se espera $\beta < 0$.

(c) Para que el ARMAX sea estacionario se requieren **dos condiciones simultáneas**: (i) todas las raíces de $\varphi_p(z) = 0$ fuera del círculo unitario; (ii) $x_t \sim I(0)$. Si $x_t \sim I(1)$, debe diferenciarse: $(1-B)Y_t = \beta(1-B)x_t + \cdots$ (o modelar la cointegración explícitamente si existe).

(d) Comparar $\mathrm{BIC}_{\mathrm{ARIMAX}}$ vs. $\mathrm{BIC}_{\mathrm{ARIMA}}$. Si $\mathrm{BIC}_{\mathrm{ARIMAX}} < \mathrm{BIC}_{\mathrm{ARIMA}}$, la reducción en $-2\log\hat{L}$ compensa la penalización por el parámetro adicional β. Para selección de modelo (determinar si x_t pertenece al modelo verdadero), usar **BIC**. Para optimizar el pronóstico fuera de muestra, usar **AIC** o validación cruzada directa.

Ejercicio 4.2 — SARIMAX demanda eléctrica

Demanda horaria D_t con doble estacionalidad y temperatura como exógena. (a) Justifique órdenes y signo de β_1. (b) Log-verosimilitud condicional. (c) Pronóstico $h = 1, \ldots, 24$ y tratamiento de Temp_{T+h}. (d) ECMP vs. naïve estacional.

Respuesta 4.2

(a) $(1-B^{24})$ elimina el patrón diario (picos de $\hat{\rho}(24k)$ persistentes). $(1-B)$ elimina la tendencia de largo plazo en la demanda (crecimiento económico). Temp_t: en verano $\beta_1 > 0$ (calor $\Rightarrow$ A/C $\Rightarrow$ mayor demanda); en invierno $\beta_1 < 0$ (frío $\Rightarrow$ calefacción eléctrica o menor demanda si se usa gas). En la práctica, la relación es en U (demanda alta con temperaturas extremas en ambas direcciones), lo que justifica incluir también Temp_t^2.
(b) La log-verosimilitud condicional (dado el vector inicial) es:

$$\ell(\varphi, \theta, \beta, \sigma^2) = -\frac{T}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum_{t=t_0}^{T}\varepsilon_t^2,$$

donde $\varepsilon_t = D_t - \varphi(B)(1-B^{24})(1-B)^{-1}[\beta_0 + \beta_1\text{Temp}_t] - \theta(B)\varepsilon_{t-1}$ es el error de innovación calculado recursivamente.
(c) Los pronósticos $\hat{D}_{T+h}$ se calculan por la recursión hacia adelante del modelo. Para Temp_{T+h}: (i) usar pronóstico meteorológico (disponible con alta precisión hasta 72 h); (ii) para $h > 72$ h, ajustar AR separado para Temp_t y propagar la incertidumbre $\hat{\sigma}^2_{\text{Temp}}$ al intervalo de D_t como componente adicional de varianza.
(d) $\text{ECMP}_{\text{naïve}} = \frac{1}{72}\sum_{h=1}^{72}(D_{T+h-168} - D_{T+h})^2$ (repetir semana anterior). El SARIMAX supera al naïve cuando hay cambios de temperatura inusuales respecto a la semana anterior o cuando la demanda tiene tendencia creciente no capturada por la mera repetición.

Ejercicio 4.3 — SARIMAX ventas con calendario

$(1-B)(1-B^{52})\log V_t = \beta_1 F_t + \beta_2 \Delta\log P_t + (1+\theta B)(1+\Theta B^{52})\varepsilon_t$. (a) Interprete β_1 y β_2. (b) ¿Por qué transformar con log? (c) FIV y multicolinealidad. (d) Pronóstico a 12 semanas con incertidumbre en P_{T+h}.

Respuesta 4.3

(a) β_1: efecto porcentual de días festivos sobre las ventas. Si $\beta_1 = 0.15$, las semanas con festivos tienen un 15% más de ventas que las semanas normales (ceteris paribus). β_2: elasticidad de las ventas respecto al cambio porcentual en el precio del petróleo. Si $\beta_2 = -0.08$, un aumento del 10% en el precio del petróleo reduce las ventas en 0.8% (efecto ingreso: los consumidores gastan más en combustible y menos en el supermercado).
(b) Tres razones para $\log V_t$:

(i) *Estabilización de varianza:* Las ventas en niveles tienen varianza proporcional al nivel (heterocedasticidad). El logaritmo transforma a varianza aproximadamente constante.
(ii) *Interpretación porcentual:* Los coeficientes β se interpretan directamente como elasticidades o efectos porcentuales, lo que es natural en economía.
(iii) *Normalidad de residuos:* La distribución de ventas en niveles es sesgada a la derecha; el logaritmo la acerca a la normalidad, mejorando la validez de los IC.

(c) $\text{FIV}_j = 1/(1-R_j^2)$ donde R_j^2 es el coeficiente de determinación de la regresión de x_j sobre los demás regresores. Problemático si FIV>10. F_t (binaria de festivos) y $\Delta\log P_t$ (cambio en precio del petróleo) son estructuralmente independientes; su FIV debería ser cercano a 1. Si

hubiera multicolinealidad: eliminar la variable menos relevante según BIC, o combinarlas en un índice compuesto.

(d) La varianza total del pronóstico de $\log V_{T+h}$ tiene dos fuentes:

$$\mathrm{Var}(\widehat{\log V}_{T+h}) = \underbrace{\hat{\sigma}^2 \sum_{j=0}^{h-1} \psi_j^2}_{\text{incertidumbre del modelo SARIMA}} + \underbrace{\hat{\beta}_2^2 \cdot \mathrm{Var}(\widehat{\Delta \log P}_{T+h})}_{\text{incertidumbre por predicción de } P} .$$

El segundo término crece con h porque $\mathrm{Var}(\widehat{\Delta \log P}_{T+h}) = \hat{\sigma}_P^2 \sum_{j=0}^{h-1} \psi_{P,j}^2$ a su vez se expande. El intervalo de predicción debe incorporar *ambas* fuentes para ser válido; ignorar la incertidumbre en P_{T+h} subestimaría la amplitud del intervalo.

5. Simulación, Yule-Walker e interpretación gráfica

Ejercicio 5.1 — Yule-Walker

(a) Derive Yule-Walker para AR(1). (b) Resuelva el sistema para AR(2) con $\varphi_1 = 0.6$, $\varphi_2 = -0.2$. (c) Consistencia y Cholesky. (d) Aplique con $T = 1000$ al IPC y construya IC al 95% para $\rho(1)$.

Respuesta 5.1

(a) Yule-Walker para AR(1).
Multiplicando $Y_t = \varphi_1 Y_{t-1} + \varepsilon_t$ por Y_{t-k} y tomando $\mathrm{E}[\cdot]$:

$$\gamma(k) = \varphi_1 \gamma(k-1) + \underbrace{\mathrm{E}[\varepsilon_t Y_{t-k}]}_{=0 \text{ para } k \geq 1}.$$

Para $k = 1$: $\gamma(1) = \varphi_1 \gamma(0) \Rightarrow \boxed{\varphi_1 = \rho(1)}$.
Para la varianza del ruido: $\gamma(0) = \varphi_1 \gamma(1) + \sigma^2 = \varphi_1^2 \gamma(0) + \sigma^2 \Rightarrow \boxed{\sigma^2 = \gamma(0)(1 - \varphi_1^2)}$.
(b) AR(2): $\varphi_1 = 0.6$, $\varphi_2 = -0.2$.
Las ecuaciones de Yule-Walker para $k = 1, 2$ son:

$$\gamma(1) = \varphi_1 \gamma(0) + \varphi_2 \gamma(1) \implies \gamma(1)(1 - \varphi_2) = \varphi_1 \gamma(0) \implies \gamma(1) = \frac{0.6}{1.2}\gamma(0) = 0.5\gamma(0).$$
$$\gamma(2) = \varphi_1 \gamma(1) + \varphi_2 \gamma(0) = 0.6(0.5\gamma(0)) + (-0.2)\gamma(0) = 0.1\gamma(0).$$

De $\sigma^2 = \gamma(0) - \varphi_1 \gamma(1) - \varphi_2 \gamma(2) = \gamma(0)(1 - 0.30 + 0.02) = 0.72\gamma(0)$:

$$\boxed{\gamma(0) = \frac{\sigma^2}{0.72}, \quad \gamma(1) = \frac{\sigma^2}{1.44}, \quad \gamma(2) = \frac{\sigma^2}{7.2}.}$$

(c) El estimador Yule-Walker sustituye $\gamma(k)$ por $\hat{\gamma}(k) = T^{-1} \sum_t Y_t Y_{t-k}$. Por la LGN para procesos ergódicos estacionarios, $\hat{\gamma}(k) \xrightarrow{p} \gamma(k)$, lo que implica $\hat{\varphi} \xrightarrow{p} \varphi$ (consistencia). La matriz de Toeplitz $\hat{\Gamma}_p$ es simétrica y definida positiva; su descomposición de Cholesky $\hat{\Gamma}_p = LL^\top$ permite resolver $\hat{\Gamma}_p \hat{\varphi} = \hat{\gamma}_p$ en $O(p^2)$ operaciones (dos sustituciones triangulares), frente a $O(p^3)$ de la inversión directa.
(d) Aplicación IPC, $T = 1000$.
Yule-Walker $p = 1$: $\hat{\varphi}_1 = \hat{\rho}(1) = 0.12$.
Banda de significancia: $\pm 1.96/\sqrt{1000} = \pm 0.062$.
IC 95% para $\rho(1)$: $0.12 \pm 0.062 = [\mathbf{0.058}, \mathbf{0.182}]$. El intervalo no contiene cero $\Rightarrow$ **estadísticamente significativo** al 5%.
Yule-Walker $p = 2$:

$$\hat{\varphi}_1 \approx \frac{\hat{\rho}(1) - \hat{\rho}(2)\hat{\rho}(1)}{1 - \hat{\rho}(1)^2} = \frac{0.12 + 0.0048}{0.9856} \approx 0.127, \quad \hat{\varphi}_2 \approx \frac{-0.04 - 0.0144}{0.9856} \approx -0.055.$$

Ejercicio 5.2 — Simulación AR(2)

$T = 300$ observaciones de $Y_t = 0.7Y_{t-1} - 0.3Y_{t-2} + \varepsilon_t$. (a) Identifique el modelo por ACF/PACF. (b) Estime por Yule-Walker. (c) Calcule las raíces complejas y su módulo. (d) Calcule $\gamma(0)$ teórica.

Respuesta 5.2

(a) La ACF decae con oscilaciones amortiguadas (indicativo de raíces complejas del polinomio AR); la PACF se corta en el rezago **2** (los coeficientes de correlación parcial son significativos en $k = 1$ y $k = 2$, prácticamente cero para $k \geq 3$). Esto es la firma de un **AR(2)**.
(b) Sistema Yule-Walker con $\hat{\rho}(1) = 0.61$, $\hat{\rho}(2) = 0.22$:

$$0.61 = \hat{\varphi}_1 + 0.61\hat{\varphi}_2, \qquad 0.22 = 0.61\hat{\varphi}_1 + \hat{\varphi}_2.$$

Sustituyendo $\hat{\varphi}_2 = 0.22 - 0.61\hat{\varphi}_1$ en la primera:

$$0.61 = \hat{\varphi}_1 + 0.61(0.22 - 0.61\hat{\varphi}_1) \implies 0.4758 = 0.6279\hat{\varphi}_1 \implies \boxed{\hat{\varphi}_1 \approx 0.758, \quad \hat{\varphi}_2 \approx -0.242.}$$

La pequeña discrepancia con los valores verdaderos $(0.7, -0.3)$ es variabilidad muestral con $T = 300$.
(c) Raíces de $1 - 0.7z + 0.3z^2 = 0$**.**

$$z = \frac{0.7 \pm \sqrt{0.49 - 1.2}}{0.6} = \frac{0.7 \pm i\sqrt{0.71}}{0.6} = \frac{0.7 \pm 0.843i}{0.6}.$$

$$|z| = \frac{\sqrt{0.49 + 0.711}}{0.6} = \frac{\sqrt{1.201}}{0.6} \approx \frac{1.096}{0.6} \approx \boxed{1.826 > 1.}$$

Las raíces son complejas con módulo $> 1 \Rightarrow$ proceso estacionario. Las raíces complejas implican que la ACF teórica tiene la forma:

$$\rho(k) = r^{-k}[A\cos(k\omega_0) + B\sin(k\omega_0)], \quad r = |z| \approx 1.826, \quad \omega_0 = \arctan(0.843/0.7) \approx 0.876 \text{ rad.}$$

Es decir, la ACF oscila con frecuencia $\omega_0/(2\pi) \approx 0.139$ ciclos por periodo, con amplitud decayendo a tasa r^{-k}.
(d) Con $\varphi_1 = 0.7$, $\varphi_2 = -0.3$, $\sigma^2 = 1$:

$$\gamma(0) = \frac{\sigma^2(1 - \varphi_2)}{(1 - \varphi_2)(1 - \varphi_1^2 - \varphi_2^2) - 2\varphi_1^2\varphi_2} = \frac{1.3}{1.3(1 - 0.49 - 0.09) - 2(0.49)(-0.3)} = \frac{1.3}{1.3(0.42) + 0.294} = \frac{1.3}{0.840} \approx \boxed{}$$

Ejercicio 5.3 — Tabla de rendimientos IPC

Interprete la tabla de estadísticas de log-retornos del IPC. Estime AR(1) por Yule-Walker para Jul-Dic 2020. Discuta si ARIMA$(1,0,0)$ es apropiado para Ene-Jun 2020. Simule 126 observaciones y compare ACF.

Respuesta 5.3

(a) Interpretación. El periodo Ene-Jun 2020 tiene la mayor volatilidad ($\hat{\sigma} = 0.0221$), la mayor asimetría negativa (-0.87) y la mayor curtosis (6.23). Esto corresponde al inicio de la pandemia COVID-19 (marzo 2020): caídas bruscas seguidas de rebotes violentos. La curtosis > 3 en todos los periodos confirma colas más gruesas que la normal (*fat tails*): los retornos extremos son más frecuentes de lo que predice el modelo gaussiano.
(b) AR(1) para Jul-Dic 2020, $T \approx 126$.
$\hat{\varphi}_1 = \hat{\rho}(1) = 0.12$, $\hat{\sigma}^2 = (0.0148)^2(1 - 0.0144) \approx 2.156 \times 10^{-4}$.
IC 95%: $0.12 \pm 1.96/\sqrt{126} = 0.12 \pm 0.175 = [-0.055,\ 0.295]$.
El intervalo contiene cero $\Rightarrow$ con sólo 126 observaciones, $\hat{\varphi}_1 = 0.12$ **no es estadísticamente significativo**. Necesitaríamos $T > [(1.96/0.12)^2 + \text{corrección}] \approx 267$ observaciones para detectar esta autocorrelación con potencia razonable.
(c) Un ARIMA$(1,0,0)$ captura la pequeña autocorrelación pero es **insuficiente** para Ene-Jun 2020: la curtosis de 6.23 indica distribución leptocúrtica (colas gruesas) que el modelo gaussiano no captura; la desviación estándar de 0.0221 comparada con 0.0117 en Jul-Dic 2023 evidencia heterocedasticidad condicional (*volatility clustering*). La extensión necesaria es ARIMA$(1,0,0)$-**GARCH**$(1,1)$ con distribución t-Student para z_t.
(d) ACF teórica: $\rho(k) = 0.12^k$ (casi cero para $k \geq 2$, igual a 0.0144 para $k = 2$). La ACF muestral de 126 observaciones diferirá por: variabilidad muestral (± 0.175), sesgo de orden $1/T$, y la correlación entre estimadores $\hat{\rho}(k)$ a rezagos distintos. Con muestras tan pequeñas, la ACF empírica es muy ruidosa y la mayoría de los rezagos serán indistinguibles de cero.

Ejercicio 5.4 — Simulación SARIMA estacional

SARIMA$(0,0,1)(1,0,0)_{12}$: $(1 - \Phi_1 B^{12})Y_t = (1 + \theta_1 B)\varepsilon_t$, $\Phi_1 = 0.8$, $\theta_1 = -0.5$. ACF simulada: $\hat{\rho}(12) \approx 0.72$, $\hat{\rho}(24) \approx 0.55$, $\hat{\rho}(36) \approx 0.41$. Interprete, calcule ACF teórica, proponga modelo y evalúe sesgo del estimador.

Respuesta 5.4

(a) Los picos en $k = 12, 24, 36$ con valores decrecientes indican un ciclo anual fuerte con memoria que se disipa. El decaimiento $0.72 \to 0.55 \to 0.41$ corresponde aproximadamente a Φ_1^k con $\Phi_1 \approx 0.8$: $0.8^1 = 0.80$, $0.8^2 = 0.64$, $0.8^3 = 0.51$ (los valores simulados son algo menores por el sesgo de estimación con $T = 120$).
(b) ACF teórica.

Para el SARIMA$(0,0,1)(1,0,0)_{12}$, la ACF se puede calcular mediante la relación:

$$\rho(1) = \frac{\theta_1}{1+\theta_1^2} = \frac{-0.5}{1.25} = -0.4, \quad \rho(k) = 0 \text{ para } 2 \le k \le 11,$$

$$\rho(12) = \Phi_1 \cdot (1+\theta_1^2)^{-1} \cdot (1+\theta_1^2) \cdot \gamma(0)^{-1} \cdot \gamma(12) \approx \Phi_1 = 0.8,$$

$$\rho(13) = \rho(12) \cdot \rho(1) = 0.8 \times (-0.4) = -0.32, \quad \rho(24) = \Phi_1^2 = 0.64.$$

(c) De la ACF observada: picos en $k = 12, 24, 36$ decayendo $\Rightarrow$ AR estacional $P = 1$; pico en $k = 1$ (si es negativo, o ausencia de picos no estacionales) $\Rightarrow$ MA regular $q = 1$; no hay picos grandes fuera de múltiplos de 12 $\Rightarrow p = 0$; picos decayendo sin crecer $\Rightarrow$ sin diferenciación ($d = D = 0$). Modelo propuesto: **SARIMA**$(0,0,1)(1,0,0)_{12}$. ✓

(d) Sesgo Yule-Walker. $\hat{\Phi}_1 = \hat{\rho}(12) = 0.72$ vs. $\Phi_1 = 0.80$. Error: -0.08 (-10%). Con $T = 120$ y $s = 12$, sólo hay 10 ciclos completos para estimar el parámetro estacional. El sesgo asintótico del estimador de autocorrelación es $\approx -(1+3\rho^2)/T \approx -0.024$; el sesgo observado de -0.08 es mayor porque la muestra efectiva de 10 ciclos es insuficiente para que las propiedades asintóticas apliquen bien.

Ejercicio 5.5 — Comparación de modelos

Tabla comparativa para tipo de cambio MXN/USD ($n = 36$ meses, prueba: últimos 6 meses). (a) Interprete la tabla. (b) Amplitud del IC al 95% en $h = 6$. (c) Calcule $\hat{Y}_{T+1|T}$ y $\hat{Y}_{T+2|T}$. (d) Estrategia de cobertura cambiaria.

Respuesta 5.5

(a) Interpretación.

Modelo	AIC	BIC	RMSE	MAE	$\hat{\sigma}^2$	Pars.
ARIMA(1,1,0)	-48.2	-45.1	0.341	0.278	0.0118	1
ARIMA(1,1,1)	-51.7	-47.0	0.312	0.251	0.0103	2
SARIMA(1,1,1)(1,0,1)$_{12}$	**-54.3**	-47.8	**0.298**	**0.239**	0.0098	4

El SARIMA gana en AIC, RMSE y MAE. En BIC la ventaja sobre ARIMA(1,1,1) es estrecha (-47.8 vs. -47.0): los 2 parámetros estacionales adicionales casi no compensan la penalización BIC con $n = 36$ observaciones. **AIC y BIC no coinciden** en la magnitud de la diferencia, aunque ambos señalan al SARIMA como mejor.

(b) Amplitud del IC al 95% en $h = 6$ (aproximación ARIMA(1,1,0)):

$$2 \times 1.96 \times \sqrt{\hat{\sigma}^2} \times \sqrt{h} = 2 \times 1.96 \times \sqrt{0.0118} \times \sqrt{6} = 3.92 \times 0.1086 \times 2.449 \approx \mathbf{1.04} \text{ MXN/USD}.$$

Una amplitud de \$1.04 a 6 meses es considerable para planear coberturas; muestra por qué los intervalos de predicción son indispensables (el punto central solo no basta).

(c) Con $\hat{\varphi}_1 = 0.3$, $\hat{\theta}_1 = -0.4$, $\Delta Y_T = 0.16$, $\hat{\varepsilon}_T = 0.05$:

$$\Delta\hat{Y}_{T+1|T} = 0.3(0.16) + (-0.4)(0.05) = 0.048 - 0.020 = 0.028 \implies \hat{Y}_{T+1|T} = Y_T + 0.028.$$

$$\Delta\hat{Y}_{T+2|T} = 0.3(0.028) + (-0.4)(0) = 0.0084 \implies \hat{Y}_{T+2|T} = Y_T + 0.0364.$$

(Para $h = 2$, $\mathrm{E}[\varepsilon_{T+1}] = 0$, por lo que el término MA desaparece.)
(d) Cobertura cambiaria. La importadora necesita comprar dólares en 3 meses ($h = 3$). Opciones:

- *Forward al punto central $\hat{Y}_{T+3}$:* Fija el tipo de cambio esperado. Adecuado si la empresa tolera pequeñas variaciones y tiene márgenes amplios.
- *Forward o put al percentil 95% (LS del IC):* Cubre el escenario adverso. La empresa paga una prima mayor pero garantiza que el costo en pesos de los dólares no superará ese nivel, protegiendo el margen operativo.

Recomendación: Para una importadora con márgenes ajustados, usar el **percentil 95%** como precio de ejercicio del put cambiario. El costo de la prima es análogo a un seguro: se paga certeza a cambio de sacrificar algo de rentabilidad en escenarios favorables.

Ejercicio 5.6 — Monte Carlo

(a) Demuestre $Y_{T+h}|Y_T = y_0 \sim \mathcal{N}(\varphi_1^h y_0, \sigma^2(1-\varphi_1^{2h})/(1-\varphi_1^2))$. (b) Calcule la tabla de IC analíticos para $\varphi_1 = 0.6$, $\sigma = 1$, $y_0 = 2$. (c) Describa el algoritmo Monte Carlo. (d) Interprete el fan chart.

Respuesta 5.6

(a) Distribución condicional.
Por sustitución recursiva en $Y_{T+j} = \varphi_1 Y_{T+j-1} + \varepsilon_{T+j}$:

$$Y_{T+h} = \varphi_1^h Y_T + \sum_{j=0}^{h-1} \varphi_1^j \varepsilon_{T+h-j}.$$

Dado $Y_T = y_0$, Y_{T+h} es combinación lineal de normales independientes (pues los ε son *i.i.d.* $\mathcal{N}(0, \sigma^2)$), por tanto también es normal con:

$$\mathrm{E}[Y_{T+h}|Y_T = y_0] = \varphi_1^h y_0, \qquad \mathrm{Var}(Y_{T+h}|Y_T = y_0) = \sigma^2 \sum_{j=0}^{h-1} \varphi_1^{2j} = \sigma^2 \frac{1-\varphi_1^{2h}}{1-\varphi_1^2}.$$

$$\boxed{Y_{T+h}|Y_T = y_0 \sim \mathcal{N}\left(\varphi_1^h y_0,\ \sigma^2 \frac{1-\varphi_1^{2h}}{1-\varphi_1^2}\right).} \quad \checkmark$$

(b) Tabla. Con $\varphi_1 = 0.6$, $\sigma = 1$, $y_0 = 2$:

h	$\mathrm{E}[Y_{T+h}] = 0.6^h \cdot 2$	$\mathrm{Var}(Y_{T+h}) = \frac{1-0.36^h}{0.64}$	LI 95%	LS 95%
1	1.200	1.000	−0.760	3.160
5	0.156	1.550	−2.284	2.596
10	0.012	1.562	−2.439	2.463
∞	0.000	1.5625	−2.450	2.450

La media converge a 0 (media incondicional) y la varianza a $\sigma^2/(1-\varphi_1^2) = 1.5625$ (varianza incondicional).
(c) Algoritmo Monte Carlo.

1. Estimar el modelo: $\hat{\varphi}_1 = 0.6$, $\hat{\sigma}^2 = 1$.
2. Para $b = 1, \ldots, 1000$:
   (a) Generar $\varepsilon_{T+1}^{(b)}, \ldots, \varepsilon_{T+h}^{(b)} \overset{i.i.d.}{\sim} \mathcal{N}(0,1)$.
   (b) Calcular $Y_{T+j}^{(b)} = 0.6\, Y_{T+j-1}^{(b)} + \varepsilon_{T+j}^{(b)}$ para $j = 1, \ldots, h$, con $Y_T^{(b)} = y_0 = 2$.
3. Para cada h, el IC empírico es $[\text{percentil}_{2.5\%}\{Y_{T+h}^{(b)}\}, \text{percentil}_{97.5\%}\{Y_{T+h}^{(b)}\}]$.

Con $B = 1000$, la diferencia con el IC analítico es $O(1/\sqrt{B}) \approx 0.032$ en términos de desviación estándar de la estimación Monte Carlo. Aumentar a $B = 10000$ reduce el error a ≈ 0.01.

(d) Interpretación del fan chart.

El abanico de pronósticos (*fan chart*) es la representación visual de los cuantiles de Y_{T+h} para $h = 1, 2, \ldots$ Las zonas más oscuras corresponden a percentiles centrales (e.g., 50-68%) y las más claras a los extremos (e.g., 5-95%).

- *¿Por qué se abre?* Porque $\text{Var}(Y_{T+h})$ crece monotónicamente con h: cada error ε_{T+j} no observado añade varianza.
- *¿Hacia dónde converge la media?* La media $\varphi_1^h y_0 \to 0$ (media incondicional del proceso) porque $|\varphi_1| < 1$.
- *¿Qué pasa con la incertidumbre cuando $h \to \infty$?* La varianza converge a $\sigma^2/(1-\varphi_1^2) = 1.5625$: el abanico **deja de abrirse** y las bandas se estabilizan. Pronosticar muy lejos en el futuro equivale a muestrear de la distribución estacionaria del proceso, independientemente del valor inicial y_0.

Aplicación en política monetaria: El Banco de Inglaterra popularizó el fan chart en sus reportes de inflación. La asimetría del fan chart (cuando la distribución predictiva es sesgada) comunica de forma intuitiva que los riesgos no son simétricos: e.g., en periodos de incertidumbre, el abanico puede ser más ancho hacia arriba (riesgo de inflación alta) que hacia abajo.

Resumen final nivel Quant. Los modelos ARIMA/SARIMA/SARIMAX son el punto de partida del análisis de series de tiempo en finanzas, pero rara vez el punto final. En la práctica se combinan con: (i) modelos de volatilidad condicional (GARCH, EGARCH, HAR-RV) para capturar heterocedasticidad; (ii) modelos de factores (PCA, DFM) para series múltiples; (iii) modelos de estado-espacio (filtro de Kalman) para parámetros variables en el tiempo; (iv) machine learning (LSTM, Transformers) para capturar no linealidades. La robustez de cualquier modelo debe evaluarse fuera de muestra con múltiples métricas (RMSE, MAE, cobertura del IC, Sharpe de la estrategia derivada) y con pruebas de estabilidad estructural (Chow, CUSUM).